

Tugas SML: Customer Segmentation dengan Clustering

Dataset Online Retail II — UCI Machine Learning Repository

Sala Jalaludin (3338240016)

02 June 2026

Contents

1	Load Libraries	3
2	Import Dataset	3
2.1	Pemeriksaan Missing Value	3
3	Data Cleaning	4
4	Pembentukan Fitur RFM	4
4.1	Distribusi Fitur RFM	5
5	Scaling	5
6	Penentuan Jumlah Cluster Optimal	6
6.1	Elbow Method	6
6.2	Silhouette Method	7
7	Metode Clustering 1: K-Means	7
7.1	Visualisasi K-Means (PCA 2D)	8
8	Metode Clustering 2: Gaussian Mixture Model (GMM)	8
8.1	Visualisasi GMM (BIC)	9
8.2	Visualisasi GMM (Cluster Plot PCA 2D)	9
9	Metode Clustering 3: Hierarchical Clustering	10
9.1	Visualisasi Dendrogram dan Cutting Tree	10
10	Metode Clustering 4: Partitioning Around Medoids (K-Medoids)	10
10.1	Visualisasi PAM (PCA 2D)	11
11	Metode Clustering 5: DBSCAN	11
11.1	Penentuan eps dengan k-Distance Plot	11
12	Validasi Cluster	12
12.1	Silhouette Width	13
12.2	Davies-Bouldin Index	14

12.3	Calinski-Harabasz Index	14
12.4	Validasi Lengkap Semua Algoritma	14
12.5	Tabel Kontingensi Antar-Algoritma	15
13	Profil Cluster	15
13.1	Visualisasi Profil Radar / Bar	16
13.2	Interpretasi Setiap Cluster	16
13.2.1	Cluster 1: Pelanggan Aktif / Bernilai Tinggi	16
13.2.2	Cluster 2: Pelanggan Tidak Aktif / Bernilai Rendah	16

1 Load Libraries

2 Import Dataset

Dataset **Online Retail II** dari UCI Machine Learning Repository berisi 541.909 transaksi toko online di Inggris tahun 2009–2011. Dataset tersedia dalam dua sheet Excel; kita gunakan kedua sheet dan gabungkan.

Download: <https://archive.uci.edu/dataset/502/online+retail+ii>

```
## Dimensi awal: 1067371 baris x 8 kolom
```

```
## Rows: 1,067,371
```

```
## Columns: 8
```

```
## $ Invoice      <chr> "489434", "489434", "489434", "489434", "489434", "489434", "48943~
## $ StockCode    <chr> "85048", "79323P", "79323W", "22041", "21232", "22064", "21871", "~
## $ Description  <chr> "15CM CHRISTMAS GLASS BALL 20 LIGHTS", "PINK CHERRY LIGHTS", "WHIT~
## $ Quantity     <dbl> 12, 12, 12, 48, 24, 24, 24, 10, 12, 12, 24, 12, 10, 18, 3, 16, 3, ~
## $ InvoiceDate   <dtm> 2009-12-01 07:45:00, 2009-12-01 07:45:00, 2009-12-01 07:45:00, 20~
## $ Price        <dbl> 6.95, 6.75, 6.75, 2.10, 1.25, 1.65, 1.25, 5.95, 2.55, 3.75, 1.65, ~
## $ `Customer ID` <dbl> 13085, 13085, 13085, 13085, 13085, 13085, 13085, 13085, 13085, 130~
## $ Country      <chr> "United Kingdom", "United Kingdom", "United Kingdom", "United King~
```

2.1 Pemeriksaan Missing Value

Sebelum data dibersihkan, dilakukan pemeriksaan nilai kosong (NA) pada setiap kolom. Bagian ini penting karena clustering tidak dapat bekerja dengan baik jika fitur numerik masih mengandung nilai hilang.

Table 1: Ringkasan Missing Value per Kolom

	Kolom	Missing	Persentase
Invoice	Invoice	0	0.00
StockCode	StockCode	0	0.00
Description	Description	4382	0.41
Quantity	Quantity	0	0.00
InvoiceDate	InvoiceDate	0	0.00
Price	Price	0	0.00
Customer ID	Customer ID	243007	22.77
Country	Country	0	0.00

```
## Total missing value: 247389
```

```
## Missing Customer ID: 243007
```

3 Data Cleaning

Transaksi yang tidak valid (retur, harga/kuantitas negatif, CustomerID kosong) harus dihapus sebelum analisis.

```
## Setelah cleaning: 805549 baris
```

```
## Jumlah unique customer: 5878
```

4 Pembentukan Fitur RFM


Data transaksi diubah menjadi **satu baris per pelanggan** menggunakan analisis **RFM** (Recency, Frequency, Monetary).

Fitur	Definisi
Recency	Hari sejak transaksi terakhir (lebih kecil = lebih aktif)
Frequency	Jumlah invoice unik (lebih besar = lebih loyal)
Monetary	Total nilai belanja dalam GBP

```
## Jumlah baris RFM: 5878
```

```
##      Recency      Frequency      Monetary
##  Min.   : 1.00   Min.   : 1.000   Min.   : 2.95
## 1st Qu.: 26.05   1st Qu.: 1.000   1st Qu.: 348.76
## Median : 96.04   Median : 3.000   Median : 898.92
## Mean   :201.85   Mean   : 6.289   Mean   : 3018.62
## 3rd Qu.:380.10   3rd Qu.: 7.000   3rd Qu.: 2307.09
## Max.   :739.12   Max.   :398.000   Max.   :608821.65
```

4.1 Distribusi Fitur RFM




5 Scaling

Karena nilai Monetary bisa ribuan kali lebih besar dari Recency, variabel perlu distandarisasi agar jarak antar-objek tidak didominasi satu fitur.


6 Penentuan Jumlah Cluster Optimal

6.1 Elbow Method



6.2 Silhouette Method

Silhouette Method — Menentukan k Optimal



Kesimpulan: Berdasarkan plot Silhouette, jumlah cluster optimal yang dipilih adalah $k = 2$. Nilai Silhouette tertinggi berada pada $k = 2$, sehingga pemisahan cluster paling baik secara statistik.

7 Metode Clustering 1: K-Means

K-Means adalah algoritma partisi yang meminimalkan jumlah kuadrat jarak setiap titik ke centroid klusternya.


```
## Ukuran tiap cluster K-Means:
```

```
##
```

```
##      1      2
```

```
## 2357 3521
```

7.1 Visualisasi K-Means (PCA 2D)



8 Metode Clustering 2: Gaussian Mixture Model (GMM)

GMM adalah pendekatan berbasis model yang mengasumsikan setiap cluster mengikuti distribusi Gaussian. Berbeda dengan K-Means, GMM memberikan **probabilitas keanggotaan** (soft assignment) dan mampu menangkap bentuk cluster yang lebih fleksibel melalui matriks kovarians.

```
## Model GMM terpilih: VVV
```


```
## Ukuran tiap cluster GMM:
```

```
##
```


```
##    1    2
```

```
## 1794 4084
```


8.1 Visualisasi GMM (BIC)



8.2 Visualisasi GMM (Cluster Plot PCA 2D)



9 Metode Clustering 3: Hierarchical Clustering

Hierarchical Clustering digunakan untuk membentuk struktur kluster bertingkat. Pada analisis ini digunakan **Average Linkage** (`method = "average"`). Jumlah cluster ditentukan dengan memotong dendrogram menggunakan `cutree()` berdasarkan nilai `k_opt`.

```
## Ukuran tiap cluster Hierarchical Average Linkage:
```


```
##
```

```
##      1      2
```

```
##    17 5861
```

9.1 Visualisasi Dendrogram dan Cutting Tree

Dendrogram — Hierarchical Clustering Average Linkage



10 Metode Clustering 4: Partitioning Around Medoids (K-Medoids)


PAM atau K-Medoids mirip dengan K-Means, tetapi pusat cluster menggunakan objek aktual (*medoid*) sehingga lebih tahan terhadap outlier.

```
## Ukuran tiap cluster PAM / K-Medoids:
```

```
##
```

```
##      1      2
## 2530 3348
```

10.1 Visualisasi PAM (PCA 2D)




11 Metode Clustering 5: DBSCAN

DBSCAN mengelompokkan data berdasarkan kepadatan titik dan dapat mendeteksi noise/outlier. Parameter utama yang perlu ditentukan adalah `eps` dan `minPts`.

11.1 Penentuan `eps` dengan k-Distance Plot

Plot k-distance digunakan untuk mencari titik siku (*elbow*) sebagai kandidat nilai `eps`. Nilai `eps_opt` di bawah dapat disesuaikan berdasarkan bentuk plot.



```
## Ukuran tiap cluster DBSCAN, 0 = noise:
```

```
##
```

```
##    0    1    2
```

```
##   59 4203 1616
```

12 Validasi Cluster

Karena dataset ini tidak memiliki label kelas bawaan, analisis dilakukan sebagai **unsupervised learning murni**. Oleh karena itu, evaluasi tidak dapat memakai akurasi terhadap label asli. Sebagai gantinya, kualitas pembagian cluster **wajib** diukur menggunakan **Internal Criteria**, yaitu metrik yang menilai kualitas cluster hanya dari struktur data dan hasil pengelompokan.

Internal Criteria yang digunakan:

Metrik	Tujuan	Arah Evaluasi
Silhouette Width	Mengukur kedekatan anggota terhadap cluster sendiri dibanding cluster lain	Lebih besar lebih baik
Shadow Value	Mengukur kualitas pemisahan cluster berdasarkan nilai internal <code>cluster.stats()</code>	Lebih besar lebih baik

Metrik	Tujuan	Arah Evaluasi
Davies-Bouldin Index	Mengukur rasio kepadatan dalam cluster dan jarak antar-cluster	Lebih kecil lebih baik
Calinski-Harabasz Index	Mengukur rasio variasi antar-cluster terhadap variasi dalam cluster	Lebih besar lebih baik

Metrik-metrik tersebut digunakan untuk membandingkan semua algoritma kandidat secara objektif dan memilih hasil akhir pada `Cluster_Final`.


12.1 Silhouette Width

Mengukur seberapa mirip setiap objek dengan klusternya sendiri dibanding kluster lain. Nilai mendekati **1 = baik**.

Rata-rata Silhouette K-Means : 0.4381

Rata-rata Silhouette GMM : 0.2924

Perbandingan Rata-rata Silhouette



12.2 Davies-Bouldin Index

Mengukur rata-rata rasio dispersi dalam kluster terhadap jarak antar kluster. Nilai **lebih kecil = lebih baik**.

```
## Davies-Bouldin K-Means : 0.9693
```

```
## Davies-Bouldin GMM      : 1.0982
```

12.3 Calinski-Harabasz Index

Rasio varians antar-kluster terhadap varians dalam-kluster. Nilai **lebih besar = lebih baik**.

```
## Calinski-Harabasz K-Means : 6205.27
```

```
## Calinski-Harabasz GMM      : 3056.2
```

12.4 Validasi Lengkap Semua Algoritma

Bagian ini memperluas validasi internal agar mencakup K-Means, GMM, Hierarchical Clustering, PAM/K-Medoids, dan DBSCAN. Untuk DBSCAN, noise (`cluster = 0`) dikeluarkan dari perhitungan metrik internal karena noise tidak dihitung sebagai cluster evaluasi.

Table 2: Rangkuman Validasi Internal dan Pemilihan Algoritma Terbaik

Metode	N	K	Noise	Sil	Shad	DB	CH	Rank
K-Means	5,878	2	0	0.4381	0.4381	0.9693	6,205.27	5
HClust Avg	5,878	2	0	0.5815	0.5815	0.7459	151.62	7
PAM	5,878	2	0	0.4340	0.4340	0.9765	6,161.99	8
GMM	5,878	2	0	0.2924	0.2924	1.0982	3,056.20	11
DBSCAN	5,819	2	59	0.2784	0.2784	1.1334	2,902.03	14

```
## Algoritma clustering terbaik yang dipilih: K-Means
```

```
## Ukuran cluster final:
```

```
##
```

```
##      1      2
```

```
## 2357 3521
```

Interpretasi: Metode dengan Silhouette lebih tinggi, Calinski-Harabasz lebih besar, dan Davies Bouldin lebih kecil dianggap menghasilkan cluster yang lebih kompak dan terpisah dengan baik.

12.5 Tabel Kontingensi Antar-Algoritma

Tabel kontingensi digunakan untuk melihat kesesuaian hasil cluster antar metode. Pada bagian ini, hasil dari **algoritma terpilih** dibandingkan dengan algoritma lainnya. Semua algoritma diperlakukan sebagai kandidat yang setara.

Table 3: Tabel Kontingensi Cluster Final terhadap Algoritma Pembanding

Metode.Pembanding	Cluster_Final	1	2	0
GMM	1	7	2,350	NA
GMM	2	1,787	1,734	NA
Hierarchical Average	1	17	2,340	NA
Hierarchical Average	2	0	3,521	NA
PAM / K-Medoids	1	2,357	0	NA
PAM / K-Medoids	2	173	3,348	NA
DBSCAN	1	2,309	0	48
DBSCAN	2	1,894	1,616	11


13 Profil Cluster

Cluster yang digunakan untuk interpretasi adalah **Cluster_Final**, yaitu hasil dari algoritma terbaik berdasarkan tabel validasi internal semua algoritma.

Table 4: Profil Rata-rata RFM per Cluster

Cluster_Final	N	Recency	Frequency	Monetary
1	2,357	51.4	12.6	6,604
2	3,521	302.6	2.1	619

13.1 Visualisasi Profil Radar / Bar



13.2 Interpretasi Setiap Cluster

Berikut interpretasi bisnis berdasarkan rata-rata RFM untuk 2 cluster berdasarkan output **profil**:

13.2.1 Cluster 1: Pelanggan Aktif / Bernilai Tinggi

Deskripsi: Recency rendah, Frequency tinggi, dan Monetary tinggi; pelanggan masih aktif serta memberikan nilai transaksi besar.

Rekomendasi: Pertahankan dengan program loyalitas, rekomendasi personal, dan penawaran eksklusif.

13.2.2 Cluster 2: Pelanggan Tidak Aktif / Bernilai Rendah

Deskripsi: Recency tinggi, Frequency rendah, dan Monetary rendah; pelanggan cenderung tidak aktif dan kontribusi transaksi lebih kecil.

Rekomendasi: Lakukan kampanye reaktivasi, diskon terbatas, dan reminder produk yang relevan.

Catatan: Label segmen di atas bersifat indikatif. Sesuaikan dengan nilai aktual pada tabel **profil** yang muncul saat knit.